

Lab 3 : Principes Fondamentaux des Réseaux de Neurones Artificiels

Fiche Complète de Révision pour l'Examen

SDBDAI

Table des matières

1	Introduction au Deep Learning	3
2	Pourquoi le Deep Learning ?	3
2.1	Machine Learning Classique	3
2.2	Deep Learning	3
3	Machine Learning vs Deep Learning	4
4	Le Perceptron	4
4.1	Structure	4
4.2	Fonctionnement	4
5	Perceptron Multicouche (MLP)	4
5.1	Pourquoi plusieurs couches ?	4
6	Perceptron vs MLP	5
7	Le problème XOR	5
7.1	Pourquoi le perceptron échoue ?	5
7.2	Solution	5
8	Fonction de Coût (Loss Function)	5
8.1	MSE	5
8.2	Cross Entropy	5
9	Descente de Gradient	6
9.1	Principe	6
10	Backpropagation	6
10.1	Étape 1 : Forward Pass	6
10.2	Étape 2 : Calcul de l'erreur	6
10.3	Étape 3 : Backward Pass	6
10.4	Étape 4 : Mise à jour des poids	6
11	Optimizers	6
11.1	SGD	7
11.2	RMSprop	7
11.3	Adam	7

12 Comparaison des Optimizers	7
13 Dropout	8
13.1 Objectif	8
14 Interprétation des Courbes	8
14.1 Loss	8
14.2 Accuracy	8
14.3 Overfitting	8
15 Architecture MLP du Cas Pratique	8
16 Questions Très Probables à l'Examen	8

1 Introduction au Deep Learning

Le Deep Learning est une branche du Machine Learning basée sur les réseaux de neurones artificiels composés de plusieurs couches.

Son objectif est d'apprendre automatiquement les caractéristiques importantes des données afin d'effectuer des tâches complexes telles que :

- Reconnaissance d'images
- Reconnaissance vocale
- Traitement du langage naturel
- Détection de pannes industrielles
- Prévvision et classification

2 Pourquoi le Deep Learning ?

2.1 Machine Learning Classique

Dans le Machine Learning classique, l'utilisateur doit souvent extraire manuellement les caractéristiques pertinentes.

Exemple :

Pour reconnaître un chat dans une image :

- Forme des oreilles
- Couleur
- Texture
- Taille

Ces caractéristiques sont définies par l'humain.

2.2 Deep Learning

Le Deep Learning apprend automatiquement ces caractéristiques.

L'utilisateur fournit :

[Données $\rightarrow$ Réseau $\rightarrow$ Résultat]

Le réseau découvre lui-même les caractéristiques utiles.

Le principal avantage du Deep Learning est l'apprentissage automatique des caractéristiques (Feature Learning).

3 Machine Learning vs Deep Learning

Critère	Machine Learning	Deep Learning
Faible à moyenne	Élevée	Complexité des problèmes
Automatique	Extraction des caractéristiques	Manuelle
Quantité de données	Moyenne	Très grande
Rapide	Plus long	Temps d'entraînement
Élevée	Puissance de calcul	Faible
Performances sur images et audio	Moyennes	Excellentes

4 Le Perceptron

Le perceptron est le plus simple des réseaux de neurones.

4.1 Structure

$$[y = f(w_1x_1 + w_2x_2 + \dots + w_nx_n + b)]$$

avec :

- x_i : entrées
- w_i : poids
- b : biais
- f : fonction d'activation

4.2 Fonctionnement

1. Les entrées arrivent au neurone.
2. Chaque entrée est multipliée par un poids.
3. Les résultats sont additionnés.
4. Une fonction d'activation produit la sortie.

5 Perceptron Multicouche (MLP)

Le MLP contient plusieurs couches :

$$[\text{Entrée} \rightarrow \text{Couche Cache} \rightarrow \text{Couche Cache} \rightarrow \text{Sortie}]$$

5.1 Pourquoi plusieurs couches ?

Les couches cachées permettent :

- d'apprendre des relations complexes,
- de résoudre des problèmes non linéaires,
- d'améliorer la précision.

6 Perceptron vs MLP

Critère	Perceptron	MLP
1	Plusieurs	Nombre de couches
Non linéaires	Problèmes résolus	Linéaires
Complexité	Faible	Élevée
Faible	Forte	Puissance
Reconnaissance d'images	Exemple	AND

7 Le problème XOR

Table de vérité :

x_1	x_2	XOR
0	0	1
1	0	1
0	1	1
1	1	0

7.1 Pourquoi le perceptron échoue ?

Le problème XOR n'est pas linéairement séparable.

Aucune droite ne permet de séparer correctement les classes.

7.2 Solution

Utiliser un MLP contenant au moins une couche cachée.

8 Fonction de Coût (Loss Function)

La fonction de coût mesure l'erreur entre la sortie réelle et la sortie prédite.

Objectif :

[Erreur $\rightarrow$ *Minimum*]

8.1 MSE

Utilisée pour la régression.

[$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$]

Exemples :

- prédiction de prix
- prédiction de température

8.2 Cross Entropy

Utilisée pour la classification.

Exemples :

- chat ou chien
- panne ou fonctionnement normal
- spam ou non spam

9 Descente de Gradient

La descente de gradient permet de réduire l'erreur du modèle.

$$[W_{new} = W_{old} - \eta \frac{\partial L}{\partial W}]$$

avec :

- W : poids
- η : learning rate
- L : fonction de coût

9.1 Principe

1. Calculer l'erreur.
2. Calculer le gradient.
3. Modifier les poids.
4. Réduire l'erreur.

10 Backpropagation

La Backpropagation est l'algorithme principal d'apprentissage des réseaux de neurones.

10.1 Étape 1 : Forward Pass

Propagation des données vers la sortie.

$$[\text{Entrée} \rightarrow \text{Rseau} \rightarrow \text{Sortie}]$$

10.2 Étape 2 : Calcul de l'erreur

Comparaison entre :

- valeur réelle
- valeur prédite

10.3 Étape 3 : Backward Pass

Propagation de l'erreur vers les couches précédentes.

10.4 Étape 4 : Mise à jour des poids

Utilisation de la descente de gradient.

Sans Backpropagation, le réseau de neurones ne peut pas apprendre.

11 Optimizers

Les optimiseurs servent à mettre à jour les poids.

11.1 SGD

Stochastic Gradient Descent

Avantages

- Simple
- Peu de mémoire

Inconvénients

- Convergence lente
- Oscillations

11.2 RMSprop

Adapte automatiquement le learning rate.

Avantages

- Plus rapide que SGD
- Plus stable

11.3 Adam

Combine :

- Momentum
- RMSprop

Avantages

- Très rapide
- Très stable
- Très utilisé

12 Comparaison des Optimizers

Critère	SGD	RMSprop	Adam
Vitesse	Lente	Très rapide	Très élevée
Convergence	Rapide	Très rapide	Lente
Stabilité	Excellente	Moyenne	Bonne
Popularité	Moyenne	Bonne	Très élevée

Ordre de performance :

[Adam > RMSprop > SGD]

13 Dropout

Le Dropout désactive aléatoirement certains neurones pendant l'entraînement.

Exemple :

[O X O X O]

où :

- O = neurone actif
- X = neurone désactivé

13.1 Objectif

- Réduire l'overfitting
- Améliorer la généralisation

14 Interprétation des Courbes

14.1 Loss

Une bonne courbe :

[Loss ↓]

14.2 Accuracy

Une bonne courbe :

[Accuracy ↑]

14.3 Overfitting

Caractéristiques :

- Accuracy train élevée
- Accuracy validation faible

15 Architecture MLP du Cas Pratique

Couche	Exemple	Rôle
-	Vectorisation	128 neurones
Extraction de caractéristiques	heightDense	Anti-overfitting
64 neurones	0.3	0.3
Régularisation	Apprentissage profond	Classification
heightDropout	heightDropout	
heightDense	1 neurone	

16 Questions Très Probables à l'Examen

- 1) Pourquoi le Deep Learning ?
- 2) Différence entre Machine Learning et Deep Learning.
- 3) Différence entre Perceptron et MLP.
- 4) Pourquoi XOR pose problème ?

- 5) Qu'est-ce qu'une fonction de coût ?
- 6) Expliquer MSE et Cross Entropy.
- 7) Expliquer la descente de gradient.
- 8) Expliquer la Backpropagation.
- 9) Comparer SGD, RMSprop et Adam.
- 10) Quel est le rôle du Dropout ?
- 11) Comment interpréter Loss et Accuracy ?
- 12) Qu'est-ce que l'Overfitting ?

Résumé à retenir

- Deep Learning = apprentissage automatique des caractéristiques.
- Perceptron = problèmes linéaires.
- MLP = problèmes non linéaires.
- MSE = régression.
- Cross Entropy = classification.
- Backpropagation = calcul des gradients.
- Gradient Descent = mise à jour des poids.
- Adam > RMSprop > SGD.
- Dropout réduit l'overfitting.
- XOR nécessite un MLP.